

运筹学与优化方法

晁国清

计算机科学与技术学院



课程回顾

➤ 非精确的线搜索

➤ 变量轮换法

➤ 最速下降法



课程内容

- 牛顿法
- 修正的牛顿法
- 拟牛顿法



牛顿法

➤考虑无约束优化问题

$$\min f(\mathbf{x}), \mathbf{x} \in R^n, f(\mathbf{x}) \in R$$

$f(\mathbf{x})$ 在 \mathbf{x}^k 处具有二阶连续偏导数, 且在 \mathbf{x}^k 处的海塞矩阵 $\nabla^2 f(\mathbf{x}^k) > \mathbf{0}$, \mathbf{x}^k 是 $f(\mathbf{x})$ 的极小点的第 k 轮估计值

将 $f(\mathbf{x})$ 在 \mathbf{x}^k 处作二阶泰勒展开:

$$\begin{aligned} f(\mathbf{x}) &= f(\mathbf{x}^k) + \nabla f(\mathbf{x}^k)^T (\mathbf{x} - \mathbf{x}^k) \\ &\quad + \frac{1}{2} (\mathbf{x} - \mathbf{x}^k)^T \nabla^2 f(\mathbf{x}^k) (\mathbf{x} - \mathbf{x}^k) \\ &\quad + O(\|\mathbf{x} - \mathbf{x}^k\|^2) \end{aligned}$$

记 $Q(\mathbf{x}) = f(\mathbf{x}^k) + \nabla f(\mathbf{x}^k)^T (\mathbf{x} - \mathbf{x}^k) + \frac{1}{2} (\mathbf{x} - \mathbf{x}^k)^T \nabla^2 f(\mathbf{x}^k) (\mathbf{x} - \mathbf{x}^k)$, 有 $Q(\mathbf{x}) \approx f(\mathbf{x})$

令 $\nabla Q(\mathbf{x}) = 0$, 即 $\nabla f(\mathbf{x}^k) + \nabla^2 f(\mathbf{x}^k)(\mathbf{x} - \mathbf{x}^k) = 0$, 记 \mathbf{x}^{k+1} 为 $Q(\mathbf{x})$ 的平稳点, 则

$$\mathbf{x}^{k+1} = \mathbf{x}^k - [\nabla^2 f(\mathbf{x}^k)]^{-1} \nabla f(\mathbf{x}^k)$$

搜索方向 $d^k = -[\nabla^2 f(\mathbf{x}^k)]^{-1} \nabla f(\mathbf{x}^k)$ 即为牛顿方向



牛顿法

➤ d^k 的几何意义:

因为 $Q(x)$ 是一个二次函数, 且有 $\nabla Q(x) = \nabla f(x^k) + \nabla^2 f(x^k)(x - x^k)$, 所以

$$\nabla^2 Q(x) = \nabla^2 f(x^k) > 0$$

$Q(x)$ 是凸函数, 其平稳点 x^{k+1} 就是全局极小点

$$x^{k+1} = x^k - [\nabla^2 f(x^k)]^{-1} \nabla f(x^k)$$

由牛顿方向 $-[\nabla^2 f(x^k)]^{-1} \nabla f(x^k) = x^{k+1} - x^k$ 可见, 牛顿方向实质上就是由 x^k 指向 x^{k+1} 的方向, 也就是 $f(x)$ 的第 k 轮极小点估计值指向近似二次函数 $Q(x)$ 的极小点的方向



牛顿法(作业)

➤基本思想：对于当前点 \mathbf{x}^k 处选择牛顿方向 $\mathbf{d}^k = -[\nabla^2 f(\mathbf{x}^k)]^{-1} \nabla f(\mathbf{x}^k)$
也可以理解为：对当前点 \mathbf{x}^k 处的二次逼近函数进行最小化

$$\min f(\mathbf{x}^k) + \nabla f(\mathbf{x}^k)^T (\mathbf{x} - \mathbf{x}^k) + \frac{1}{2} (\mathbf{x} - \mathbf{x}^k)^T \nabla^2 f(\mathbf{x}^k) (\mathbf{x} - \mathbf{x}^k)$$

注意：纯牛顿法规定步长因子 $\alpha_k = 1$

基本步骤：

Step 1: 给定初始点 \mathbf{x}^0 ，终止误差 $\epsilon > 0$ ， $k=0$ ；

Step 2: 计算梯度 $\nabla f(\mathbf{x}^k)$ ，判断是否满足终止条件 $\|\nabla f(\mathbf{x}^k)\| < \epsilon$ ，满足则终止；否则 转step 3；

Step 3: 构造牛顿方向 $\mathbf{d}^k = -[\nabla^2 f(\mathbf{x}^k)]^{-1} \nabla f(\mathbf{x}^k)$

Step 4: 计算 $\mathbf{x}^{k+1} = \mathbf{x}^k + \mathbf{d}^k$ ，令 $k = k + 1$ 转step 2



牛顿法

➤ 问题：牛顿方向 $\mathbf{d}^k = -[\nabla^2 f(\mathbf{x}^k)]^{-1} \nabla f(\mathbf{x}^k)$ 一定是下降方向么？

$$\nabla f(\mathbf{x}^k)^T \mathbf{d}^k = -\nabla f(\mathbf{x}^k)^T [\nabla^2 f(\mathbf{x}^k)]^{-1} \nabla f(\mathbf{x}^k) < 0?$$

如果 $[\nabla^2 f(\mathbf{x}^k)]^{-1} > \mathbf{0}$ ，则牛顿方向是下降方向，否则不是

缺点：

1. 要求海塞矩阵正定；
2. 需要计算海塞矩阵及其逆，计算量大

优点：

1. 当初始点接近于最优解且海塞矩阵正定时，牛顿法二阶收敛；
2. 对于凸二次函数，只需要一步牛顿法即可找到最优解



修正牛顿法

➤对于步长的修正:

保留牛顿方向为搜索方向但摒弃了步长恒为1的做法，而是采用线搜索确定最优步长来构造算法

➤基本步骤:

Step 1: 给定初始点 \mathbf{x}^0 ，终止误差 $\epsilon > 0$ ， $k=0$;

Step 2: 计算梯度 $\nabla f(\mathbf{x}^k)$ ，判断是否满足终止条件 $\|\nabla f(\mathbf{x}^k)\| < \epsilon$ ，满足则终止；否则 转step 3;

Step 3: 构造牛顿方向 $\mathbf{d}^k = -[\nabla^2 f(\mathbf{x}^k)]^{-1} \nabla f(\mathbf{x}^k)$;

Step 4: 进行线搜索求 α_k 使

$$f(\mathbf{x}^k + \alpha_k \mathbf{d}^k) = \min_{\alpha \geq 0} f(\mathbf{x}^k + \alpha \mathbf{d}^k)$$

计算 $\mathbf{x}^{k+1} = \mathbf{x}^k + \alpha_k \mathbf{d}^k$ ，令 $k = k + 1$ 转step 2



修正牛顿法

➤对于方向的修正：选取 $\mathbf{d}^k = -\mathbf{B}_k^{-1} \nabla f(\mathbf{x}^k)$

若 $\nabla^2 f(\mathbf{x}^k) \succ \mathbf{0}$ ，则取 $\mathbf{B}_k = \nabla^2 f(\mathbf{x}^k)$ ；

否则，采取修正方法：

1. $\mathbf{B}_k = \nabla^2 f(\mathbf{x}^k) + \lambda \mathbf{I}$, λ 为适当的正数保证 \mathbf{B}_k 正定；

$\nabla^2 f(\mathbf{x}^k)$ 的特征值 $\lambda_1, \lambda_2, \dots, \lambda_n$ ，要求 $\lambda_i + \lambda > 0, i = 1, 2, \dots, n$

只需要取 $\lambda > \max_{i=1,2,\dots,n} \{-\lambda_i\}$

2. 考虑特征值分解 $\nabla^2 f(\mathbf{x}^k) = \mathbf{Q}^T \Lambda \mathbf{Q}$ ，其中 $\Lambda = \text{diag}(\lambda_1, \dots, \lambda_n)$ ；

令 $\mathbf{B}_k = \mathbf{Q}^T \text{diag}(\tau_i) \mathbf{Q}$,

$$\tau_i = \begin{cases} \lambda_i, & \text{if } \lambda_i \geq \delta \\ \delta, & \text{otherwise} \end{cases}, \quad \delta \text{ 为一适当正数}$$



拟牛顿法

➤ 考虑 $f(x)$ 在当前点 x^k 处的二次近似函数

$$Q_k(x) = f(x^k) + \nabla f(x^k)^T (x - x^k) + \frac{1}{2} (x - x^k)^T B_k (x - x^k)$$

其中 $B_k > 0$

利用 $\min Q_k(x)$ 得到搜索方向 $d^k = -B_k^{-1} \nabla f(x^k)$

拟牛顿法思想：使 B_k 体现一些二阶信息并且容易获取

拟牛顿法框架：

Step 1: 给定初始点 x^0 ，终止误差 $\epsilon > 0$ ， $k=0$ 以及 $B_0 > 0$ ；

Step 2: 计算梯度 $\nabla f(x^k)$ ，判断是否满足终止条件 $\|\nabla f(x^k)\| < \epsilon$ ，满足则终止；否则 转 step 3；

Step 3: 构造拟牛顿方向 $d^k = -B_k^{-1} \nabla f(x^k)$ ；

Step 4: 进行线搜索求 α_k 使

$$f(x^k + \alpha_k d^k) = \min_{\alpha \geq 0} f(x^k + \alpha d^k)$$

计算 $x^{k+1} = x^k + \alpha_k d^k$ ，确定 B_{k+1} 令 $k = k + 1$ 转 step 2



拟牛顿法

➤如何简便获取矩阵 \mathbf{B}_{k+1} ?

➤拟牛顿方程(基本要求):

$$\nabla f(\mathbf{x}^{k+1}) - \nabla f(\mathbf{x}^k) = \mathbf{B}_{k+1}(\mathbf{x}^{k+1} - \mathbf{x}^k)$$

如何理解?

已知 \mathbf{x}^k 由迭代法算出 \mathbf{x}^{k+1} , 然后计算出 $\nabla f(\mathbf{x}^{k+1})$ 和 $\nabla f(\mathbf{x}^k)$,
由微分中值定理得到:

$$\nabla f(\mathbf{x}^{k+1}) - \nabla f(\mathbf{x}^k) = \nabla^2 f(\xi)(\mathbf{x}^{k+1} - \mathbf{x}^k)$$

其中 $\xi = \lambda \mathbf{x}^k + (1 - \lambda)\mathbf{x}^{k+1}, \lambda \in (0,1)$

为方便书写, 记 $\mathbf{y}_k = \nabla f(\mathbf{x}^{k+1}) - \nabla f(\mathbf{x}^k)$, $\mathbf{s}_k = \mathbf{x}^{k+1} - \mathbf{x}^k$,
则牛顿方程变为

$$\mathbf{y}_k = \mathbf{B}_{k+1}\mathbf{s}_k$$

如果再记 $\mathbf{H}_k = \mathbf{B}_k^{-1}$, 拟牛顿方程就表示为: $\mathbf{s}_k = \mathbf{H}_{k+1}\mathbf{y}_k$



拟牛顿

➤ 求 \mathbf{B}_{k+1} 或 \mathbf{H}_{k+1} :

基于已有信息 $(\mathbf{y}_k, \mathbf{s}_k, \mathbf{B}_k)$ 获取 \mathbf{B}_{k+1}

基于已有信息 $(\mathbf{y}_k, \mathbf{s}_k, \mathbf{H}_k)$ 获取 \mathbf{H}_{k+1}

➤ 第一类方法: 选择满足拟牛顿方程且与 \mathbf{B}_k (或 \mathbf{H}_k) 近似的矩阵:

$$\begin{aligned} \min & \|\mathbf{B} - \mathbf{B}_k\| \\ \text{s.t. } & \mathbf{B}\mathbf{s}_k = \mathbf{y}_k \\ & \mathbf{B} = \mathbf{B}^T \end{aligned}$$

或

$$\begin{aligned} \min & \|\mathbf{H} - \mathbf{H}_k\| \\ \text{s.t. } & \mathbf{H}\mathbf{y}_k = \mathbf{s}_k \\ & \mathbf{H} = \mathbf{H}^T \end{aligned}$$

➤ 第二类方法: 对 \mathbf{B}_k (或 \mathbf{H}_k) 进行校正, 令 $\mathbf{B}_{k+1} = \mathbf{B}_k + \Delta\mathbf{B}$

➤ Rank-2校正, 要求 $\Delta\mathbf{B}$ 的秩为2: DFP方法, BFGS方法;

➤ Rank-1校正, 要求 $\Delta\mathbf{B}$ 的秩为1;



DFP (Davidon, Fletcher, Powell) 方法

➤DFP方法是对 \mathbf{H}_k 进行rank-2校正

$$\mathbf{H}_{k+1} = \mathbf{H}_k - \frac{\mathbf{H}_k \mathbf{y}_k \mathbf{y}_k^T \mathbf{H}_k^T}{\mathbf{y}_k^T \mathbf{H}_k \mathbf{y}_k} + \frac{\mathbf{s}_k \mathbf{s}_k^T}{\mathbf{s}_k^T \mathbf{y}_k} \quad (\text{DFP})$$

如何得到?

DFP假设 $\mathbf{H}_{k+1} = \mathbf{H}_k + \mathbf{E}_k$, 令 $\mathbf{E}_k = a\mathbf{u}_k \mathbf{u}_k^T + b\mathbf{v}_k \mathbf{v}_k^T$, 其中 $\mathbf{u}_k, \mathbf{v}_k$ 都是 $n \times 1$ 的向量, 将 $\mathbf{H}_{k+1} = \mathbf{H}_k + \mathbf{E}_k$ 带入拟牛顿方程 $\mathbf{s}_k = \mathbf{H}_{k+1} \mathbf{y}_k$ 得到

$$\mathbf{s}_k = (\mathbf{H}_k + \mathbf{E}_k) \mathbf{y}_k$$

再将 $\mathbf{E}_k = a\mathbf{u}_k \mathbf{u}_k^T + b\mathbf{v}_k \mathbf{v}_k^T$ 带入上式得到

$$\mathbf{s}_k = (\mathbf{H}_k + a\mathbf{u}_k \mathbf{u}_k^T + b\mathbf{v}_k \mathbf{v}_k^T) \mathbf{y}_k$$

$$\Rightarrow a(\mathbf{u}_k^T \mathbf{y}_k) \mathbf{u}_k + b(\mathbf{v}_k^T \mathbf{y}_k) \mathbf{v}_k = \mathbf{s}_k - \mathbf{H}_k \mathbf{y}_k \quad (*)$$

已知 $\mathbf{u}_k^T \mathbf{y}_k, \mathbf{v}_k^T \mathbf{y}_k$ 是实数, $\mathbf{s}_k - \mathbf{H}_k \mathbf{y}_k$ 为 $n \times 1$ 的向量。

假设 $\mathbf{u}_k = r\mathbf{H}_k \mathbf{y}_k, \mathbf{v}_k = \theta \mathbf{s}_k$, 则 $\mathbf{E}_k = ar^2 \mathbf{H}_k \mathbf{y}_k \mathbf{y}_k^T \mathbf{H}_k^T + b\theta^2 \mathbf{s}_k \mathbf{s}_k^T$

将 $\mathbf{u}_k = r\mathbf{H}_k \mathbf{y}_k, \mathbf{v}_k = \theta \mathbf{s}_k$ 带入上式(*)得到



DFP方法

$$\begin{aligned} \Rightarrow a[(r\mathbf{H}_k\mathbf{y}_k)^T\mathbf{y}_k](r\mathbf{H}_k\mathbf{y}_k) + b[(\theta\mathbf{s}_k)^T\mathbf{y}_k](\theta\mathbf{s}_k) &= \mathbf{s}_k - \mathbf{H}_k\mathbf{y}_k \\ \Rightarrow [ar^2\mathbf{y}_k^T\mathbf{H}_k^T\mathbf{y}_k + 1](\mathbf{H}_k\mathbf{y}_k) + [b\theta^2\mathbf{s}_k^T\mathbf{y}_k - 1](\mathbf{s}_k) &= 0 \end{aligned}$$

令 $ar^2\mathbf{y}_k^T\mathbf{H}_k^T\mathbf{y}_k + 1 = 0$, $b\theta^2\mathbf{s}_k^T\mathbf{y}_k - 1 = 0$, 则

$$ar^2 = -\frac{1}{\mathbf{y}_k^T\mathbf{H}_k^T\mathbf{y}_k}$$

$$b\theta^2 = \frac{1}{\mathbf{s}_k^T\mathbf{y}_k}$$

带入 $\mathbf{E}_k = ar^2\mathbf{H}_k\mathbf{y}_k\mathbf{y}_k^T\mathbf{H}_k^T + b\theta^2\mathbf{s}_k\mathbf{s}_k^T$

于是最终的DFP公式为

$$\mathbf{H}_{k+1} = \mathbf{H}_k - \frac{\mathbf{H}_k\mathbf{y}_k\mathbf{y}_k^T\mathbf{H}_k^T}{\mathbf{y}_k^T\mathbf{H}_k\mathbf{y}_k} + \frac{\mathbf{s}_k\mathbf{s}_k^T}{\mathbf{s}_k^T\mathbf{y}_k}$$



DFP方法

➤DFP算法步骤:

Step 0: 给定步长 $\alpha \in (0,1)$, $\sigma \in (0,0.5)$, 初始点 $\mathbf{x}_0 \in R^n$, 终止误差 ϵ , 初始对称正定矩阵 \mathbf{H}_0 (通常取为 $\mathbf{G}(\mathbf{x}_0)^{-1}$ 或单位矩阵 \mathbf{I}_n), 令 $k = 0$;

Step 1: 计算 $\mathbf{g}_k = \nabla f(\mathbf{x}_k)$, 若 $\|\mathbf{g}_k\| \leq \epsilon$, 停止计算, 输出 \mathbf{x}_k 作为近似极小点;

Step 2: 计算搜索方向:

$$\mathbf{d}_k = -\mathbf{H}_k \mathbf{g}_k;$$

Step 3: 设 m_k 是满足下列不等式的最小非负整数 m :

$$f(\mathbf{x}_k + \delta^m \mathbf{d}_k) \leq f(\mathbf{x}_k) + \sigma \delta^m \mathbf{g}_k^T \mathbf{d}_k$$

令 $\alpha_k = \delta^{m_k}$, $\mathbf{x}_{k+1} = \mathbf{x}_k + \alpha_k \mathbf{d}_k$

Step 4: 由公式 $\mathbf{H}_{k+1} = \mathbf{H}_k - \frac{\mathbf{H}_k \mathbf{y}_k \mathbf{y}_k^T \mathbf{H}_k^T}{\mathbf{y}_k^T \mathbf{H}_k \mathbf{y}_k} + \frac{\mathbf{s}_k \mathbf{s}_k^T}{\mathbf{s}_k^T \mathbf{y}_k}$ 确定 \mathbf{H}_{k+1} ;

Step 5: 令 $k = k + 1$, 转入 step 1



BFGS (Broyden, Fletcher, Goldarb, Shanno) 算法

➤BFGS可看做对 \mathbf{B}_k 进行rank-2校正

$$\mathbf{B}_{k+1} = \mathbf{B}_k + \frac{\mathbf{y}_k \mathbf{y}_k^T}{\mathbf{y}_k^T \mathbf{s}_k} - \frac{\mathbf{B}_k \mathbf{s}_k \mathbf{s}_k^T \mathbf{B}_k}{\mathbf{s}_k^T \mathbf{B}_k \mathbf{s}_k} \quad (\text{BFGS})$$

如何得到?

过程和DFS相同, DFS是依据拟牛顿方程 $\mathbf{s}_k = \mathbf{H}_{k+1} \mathbf{y}_k$, BFGS则依据拟牛顿方程 $\mathbf{y}_k = \mathbf{B}_{k+1} \mathbf{s}_k$ 。所以只需要互换 \mathbf{s}_k 和 \mathbf{y}_k 位置

拟牛顿方向需要计算 \mathbf{B}_{k+1}^{-1} , 可利用Sherman-Morrison公式显示写出

Sherman-Morrison公式: 设 $\mathbf{A} \in R^n$ 为非奇异方阵, $\mathbf{u}, \mathbf{v} \in R^n$, 若 $1 + \mathbf{v}^T \mathbf{A}^{-1} \mathbf{u} \neq 0$, 则有

$$(\mathbf{A} + \mathbf{u} \mathbf{v}^T)^{-1} = \mathbf{A}^{-1} - \frac{\mathbf{A}^{-1} \mathbf{u} \mathbf{v}^T \mathbf{A}^{-1}}{1 + \mathbf{v}^T \mathbf{A}^{-1} \mathbf{u}}$$

由Sherman-Morrison公式得到

$$\mathbf{B}_{k+1}^{-1} = \left(\mathbf{I} - \frac{\mathbf{s}_k \mathbf{y}_k^T}{\mathbf{y}_k^T \mathbf{s}_k} \right) \mathbf{B}_k^{-1} \left(\mathbf{I} - \frac{\mathbf{y}_k \mathbf{s}_k^T}{\mathbf{y}_k^T \mathbf{s}_k} \right) + \frac{\mathbf{s}_k \mathbf{s}_k^T}{\mathbf{y}_k^T \mathbf{s}_k}$$

被认为是最有效的拟牛顿法, 超线性收敛



拟牛顿法SR1方法

➤ SR1方法是对 B_k 进行rank-1校正

$$B_{k+1} = B_k + \frac{(y_k - B_k s_k)(y_k - B_k s_k)^T}{(y_k - B_k s_k)^T s_k} \quad (\text{SR1})$$

➤ 如何得到上式?

设 $B_{k+1} = B_k + a u u^T$ 需要满足拟牛顿公式 $B_{k+1} s_k = y_k$

得到 $B_k s_k + a u u^T s_k = y_k$

移项得到 $a u(u^T s_k) = y_k - B_k s_k$

令 $u = y_k - B_k s_k$, 得到

$$a(u^T s_k) = 1$$

$$\text{即 } a = \frac{1}{u^T s_k} = \frac{1}{(y_k - B_k s_k)^T s_k}$$

将 $u = y_k - B_k s_k$ 和 $a = \frac{1}{(y_k - B_k s_k)^T s_k}$ 代入 $B_{k+1} = B_k + a u u^T$, 就得到公式SR1

➤ SR1算法迭代公式简单, 但不能保证正定性; 适当条件下能达到n步超线性收敛

$$\lim_{k \rightarrow \infty} \frac{\|x^{k+1+n} - x^*\|}{\|x^k - x^*\|} = 0$$



参考文献

- 运筹学与最优化方法，第5章 Page114-126
- 最优化方法，第4章
- 最优化基础理论与方法，第三章

