

运筹学与优化方法

晁国清

计算机科学与技术学院



课程回顾

➤ 凸函数的定义

f 是定义在非空凸集 C 上的函数, 如果对于任意的 $x, y \in C$, 和 $\lambda \in [0, 1]$, 均有 $f(\lambda x + (1 - \lambda)y) \leq \lambda f(x) + (1 - \lambda)f(y)$, 则称 f 为 C 上的凸函数

➤ 常见凸函数

指数函数、幂函数 $x^a, a \geq 1$ or $a \leq 0$ over R_+ , 仿射函数、二次函数、最小平方损失, 范数、谱范数、核范数

➤ 凸函数的性质

一阶特性、二阶特性

➤ 保持凸性的操作

非负线性组合、凸函数与仿射函数的复合、逐点最大、部分最小, 一般的复合

➤ 凸集与凸函数的关系

水平集、上镜图



凸优化问题

➤ 凸优化问题

➤ 常见凸优化问题的类型



凸优化问题

最优化问题形式:
$$\begin{cases} \min_{x \in D} f(x) \\ \text{s.t. } g_i(x) \leq 0, i = 1, \dots, m \\ h_j(x) = 0, j = 1, \dots, l \end{cases}$$

- 当 $f(x)$ 是凸函数。可行域 $S = \{x \in X | g_i(x) \leq 0, i = 1, \dots, m, h_i(x) = 0, i = 1, \dots, l\}$ 是凸集合，则上述优化问题为凸优化问题
- 当 $f(x), g_i(x), i = 1, \dots, m$ 是凸函数， $h_i(x), i = 1, \dots, l$ 是线性函数，上述优化问题也称为凸优化问题



凸优化问题

- 局部最优解 \bar{x} : $f(\bar{x}) \leq f(x), \forall x \in S \cap N_\epsilon(\bar{x})$
- 全局最优解 x^* : $f(x^*) \leq f(x), \forall x \in S$
- 对于凸优化问题，局部最优解就是全局最优解？

反证法：

设 \bar{x} 是局部最优解，但不是全局最优解，即 $\exists x^* \in S$ 使
" $f(x^*) < f(\bar{x})$ "

$$\begin{aligned} \text{对于 } \lambda \in (0,1), \quad f(\bar{x} + \lambda(x^* - \bar{x})) &= f(\lambda x^* + (1 - \lambda)\bar{x}) \\ &\leq \lambda f(x^*) + (1 - \lambda)f(\bar{x}) \\ &< \lambda f(\bar{x}) + (1 - \lambda)f(\bar{x}) = f(\bar{x}) \end{aligned}$$

当 $\lambda \rightarrow 0$ ，上面不等式与 \bar{x} 是局部最优解矛盾



凸优化问题的最优性条件几何解释

➤ $x^* \in S$ 是最优解 $\Leftrightarrow \nabla f(x^*)^T (x - x^*) \geq 0, \forall x \in S$

➤ 几何解释

$x^* \in S$ 是最优解 $\Leftrightarrow \nabla f(x^*)^T (x - x^*) \geq 0, \forall x \in S$


$$\Leftrightarrow -\nabla f(x^*)^T x^* \geq -\nabla f(x^*)^T x, \forall x \in S$$

令 $\alpha = -\nabla f(x^*)$, 则有 $\alpha^T x^* \geq \alpha^T x, \forall x \in S$

如果 $\alpha \neq 0$ 即 $-\nabla f(x^*)^T \neq 0$

则 $H = \{x \mid -\nabla f(x^*)^T x = -\nabla f(x^*)^T x^*\}$ 就是集合 S 在 x^* 处的支撑超平面

如果 $\alpha = 0$ 即 $-\nabla f(x^*)^T = 0$, 就无法确立支撑超平面



凸优化问题的最优性条件证明

➤ $x^* \in S$ 是最优解 $\Leftrightarrow \nabla f(x^*)^T(x - x^*) \geq 0, \forall x \in S$

证明:

充分性: $\forall x \in S, f(x) \geq f(x^*) + \nabla f(x^*)^T(x - x^*) \geq f(x^*)$

必要性: 反证法

有 $\exists \bar{x} \in S$ 使 $\nabla f(x^*)^T(\bar{x} - x^*) < 0$

对于 $\lambda \in [0, 1], f(x^* + \lambda(\bar{x} - x^*)) - f(x^*) = \lambda \nabla f(x^*)^T(\bar{x} - x^*) + o(\lambda \|\bar{x} - x^*\|)$

两边同除以 λ , 然后令 $\lambda \rightarrow 0$, 得到

$$\frac{f(x^* + \lambda(\bar{x} - x^*)) - f(x^*)}{\lambda} < 0$$

与 $x^* \in S$ 是最优解矛盾



几种特殊凸优化问题的最优性条件

➤ 无约束凸优化问题 $\min f(x), x \in R^n$ 的最优性条件:

$$x^* \text{ 是最优解} \Leftrightarrow \nabla f(x^*) = 0$$

证明: x^* 是最优解 $\Leftrightarrow \nabla f(x^*)^T (x - x^*) \geq 0, \forall x \in R^n \Leftrightarrow \nabla f(x^*) = 0$

➤ 等式约束凸优化问题 $\min\{f(x) | Ax = b\}$ 的最优性条件:

$$x^* \text{ 是最优解} \Leftrightarrow \nabla f(x^*) + A^T \mu = 0, \exists \mu$$

证明: x^* 是最优解 $\Leftrightarrow \nabla f(x^*)^T (x - x^*) \geq 0, \forall x$ 满足 $Ax = b, Ax^* = b$

$$\Leftrightarrow \nabla f(x^*)^T d = 0, \forall d \in N(A)$$

$$\Leftrightarrow \nabla f(x^*) \in N(A)^\perp = \text{range}(A^T)$$

$$\Leftrightarrow \nabla f(x^*) + A^T \mu = 0$$



几种特殊凸优化问题的最优性条件

➤ 非负约束凸优化问题 $\min\{f(x)|x \geq 0\}$ 的最优性条件:

$$x^* \text{ 是最优解} \Leftrightarrow \nabla f(x^*)_i x_i^* = 0, x^* \geq 0, \nabla f(x^*) \geq 0$$

证明: x^* 是最优解 $\Leftrightarrow \nabla f(x^*)^T (x - x^*) \geq 0, \forall x \geq 0, x^* \geq 0$
 $\Leftrightarrow \nabla f(x^*)^T x \geq \nabla f(x^*)^T x^*, \forall x \geq 0, x^* \geq 0$
 $\Leftrightarrow \nabla f(x^*) \geq 0, x^* \geq 0, \nabla f(x^*)^T x^* = 0$
 $\Leftrightarrow \nabla f(x^*) \geq 0, x^* \geq 0, \nabla f(x^*)_i^T x_i^* = 0, i = 1, \dots, n$



常见的凸优化问题

- 线性规划 (Linear programming, LP)
- 二次规划 (Quadratic programming, QP)
- 带二次约束的二次规划 (Quadratically constrained quadratic program, QCQP)
- 二阶锥规划 (Second-order cone program, SOCP)
- 半定规划 (Semidefinite program, SDP)
- 几何规划 (Geometric programming, GP)
- ...




线性规划 (Linear programming, LP)

➤ 线性规划的标准形式

$$\begin{aligned} \min \quad & c^T x \\ \text{s.t.} \quad & Ax = b \\ & x \geq 0 \end{aligned}$$

➤ 单纯形方法求解:



如果线性规划问题存在最优解，
则最优解一定在极值点(顶点)

找到极值点 \bar{x} , 判断是否最优, 如果最优, 结束。否则从当前极值点 \bar{x} 出发寻找一个更优的极值点, 继续判断, \dots , 一直到找到最优解或发现无解

凸二次规划 (Quadratic programming, QP)

➤ 基本形式:

$$\begin{aligned} \min & \frac{1}{2} x^T Q x + c^T x \\ \text{s.t.} & Ax = b \\ & x \geq 0 \end{aligned}$$

其中, $Q \succcurlyeq 0$

➤ 例子:

均值-方差模型

最小二乘模型

$$\min \|Ax - b\|_2^2$$

$$\left\{ \begin{array}{l} \min \sum_{i,j=1}^n x_i x_j \sigma_{ij} \\ \text{s.t.} \sum_{i=1}^n x_i r_i \geq \mu \\ \sum_{i=1}^n x_i = 1 \\ x_i \geq 0, i = 1, \dots, n \end{array} \right.$$

➤ 求解方法: 有效集法



带二次约束的二次规划 (Quadratically constrained quadratic program, QCQP)

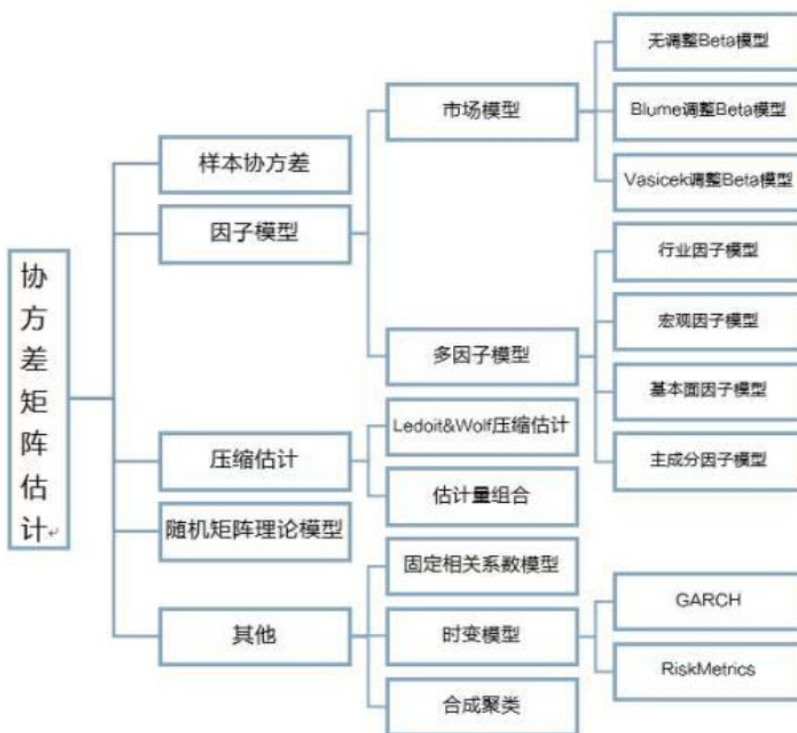
➤ 基本形式:

$$\begin{aligned} \min \quad & \frac{1}{2} x^T Q_0 x + c_0^T x \\ \text{s.t.} \quad & \frac{1}{2} x^T Q_i x + c_i^T x + b_i \leq 0, i = 1, \dots, k \\ & Ax = d \end{aligned}$$

其中, $Q_i \succeq 0, i = 0, 1, \dots, k$.

➤ 例子: 带多种风险约束的均值方差模型

图 1: 协方差矩阵估计方法梳理



二阶锥规划 (Second-order cone program, SOCP)

➤ 基本形式:

$$\begin{aligned} \min \quad & f^T x \\ \text{s. t.} \quad & \|A_i x + b_i\|_2 \leq c_i^T x + d_i, i = 1, \dots, m \\ & Fx \leq g \end{aligned}$$

$$f \in R^n, A_i \in R^{n_i \times n}, b_i \in R^{n_i}, c_i \in R^n, d_i \in R, F \in R^{p \times n}, g \in R^p, x \in R^n$$

➤ 该问题之所以称为二阶锥规划是因为约束中 $(Ax + b, c^T x + d)$ 为 R^{m+1} 空间中的二阶锥

➤ 当 $m=0$, 退化为LP

二阶锥规划例子

➤例子：一类特殊的概率约束问题 $\min\{c^T x | P(\xi^T x \leq a) \geq 95\%\}$,
其中 $\xi \sim N(\mu, Q)$

$$\xi^T x \sim N(\mu^T x, x^T Q x)$$
$$P(\xi^T x \leq a) \geq 95\% \Leftrightarrow P\left(\frac{\xi^T x - \mu^T x}{\sqrt{x^T Q x}} \leq \frac{a - \mu^T x}{\sqrt{x^T Q x}}\right) \geq 95\%$$

令 $\bar{\xi} = \frac{\xi^T x - \mu^T x}{\sqrt{x^T Q x}}$, 则有 $\bar{\xi} \sim N(0, 1)$

通过查阅标准正态分布的分位数表格可以查到对应于95%的一个值 z_c
有 $P(\bar{\xi} \leq z_c) = 95\%$

$$\begin{aligned} \text{概率约束} &\Leftrightarrow \frac{a - \mu^T x}{\sqrt{x^T Q x}} \geq z_c \\ &\Leftrightarrow \sqrt{x^T Q x} \leq \frac{1}{z_c} (a - \mu^T x) \\ &\Leftrightarrow \|Lx\|_2 \leq \frac{1}{z_c} (a - \mu^T x) \end{aligned}$$

cholesky分解得到 $Q = L^T L$,
则有

$$x^T Q x = x^T L^T L x = \|Lx\|_2^2$$



半定规划(Semidefinite program, SDP)

➤ 半定规划的标准形式:

$$\begin{aligned} \min \quad & \text{tr}(CX) \\ \text{s.t.} \quad & \text{tr}(Q_i X) = b_i, i = 1, \dots, m \\ & X \succeq 0 \end{aligned}$$

➤ 矩阵不等式形式:

$$\begin{aligned} \min \quad & c^T x \\ \text{s.t.} \quad & x_1 Q_1 + \dots + x_n Q_n \preceq Q_0 \\ & Ax = b \end{aligned}$$

线性矩阵不等式(Linear matrix inequality, LMI)



几何规划(Geometric program, GP)

➤几何规划的基本形式:

$$\begin{aligned} \min_x \quad & f(x) \\ \text{s.t.} \quad & g_i(x) \leq 1, i = 1, \dots, m \\ & h_j(x) = 1, j = 1, \dots, r \end{aligned}$$

其中 $f(x), g_i(x), i = 1, \dots, m$ 都是正项多项式, $h_j(x), j = 1, \dots, r$ 都是单项式

单项式: $f: \mathbb{R}_{++}^n \rightarrow \mathbb{R}, f(x) = \gamma x_1^{a_1} x_2^{a_2} \cdots x_n^{a_n}, \gamma > 0, a_1, \dots, a_n \in \mathbb{R}.$

正项多项式是单项式的求和: $f(x) = \sum_{k=1}^p \gamma_k x_1^{a_{k1}} x_2^{a_{k2}} \cdots x_n^{a_{kn}}$

该几何规划问题是非凸的



几何规划(Geometric program, GP)

➤对于单项式, $f(x) = \gamma x_1^{a_1} x_2^{a_2} \cdots x_n^{a_n}$, 令 $y_i = \log x_i$, 则有

$$\gamma(e^{y_1})^{a_1} (e^{y_2})^{a_2} \cdots (e^{y_n})^{a_n} = e^{a^T y + b}$$

$$b = \log \gamma$$

正项多项式就可以写作 $\sum_{k=1}^p e^{a_k^T y + b_k}$

通过上述变量转换, 并且取 \log , 前面的几何规划问题就等价于

$$\begin{aligned} \min_x \quad & \log \left(\sum_{k=1}^{p_0} e^{a_{0k}^T y + b_{0k}} \right) \\ \text{s.t.} \quad & \log \left(\sum_{k=1}^{p_i} e^{a_{ik}^T y + b_k} \right) \leq 0, i = 1, \dots, m \\ & c_j^T y + d_j = 0, j = 1, \dots, r \end{aligned}$$

此优化问题提为凸优化问题



Log-sum-exp 凸函数

- Log-sum-exp函数: $g(x) = \log(\sum_{i=1}^k e^{a_i^T x + b_i})$, 对于固定的 $a_i, b_i, i = 1, \dots, k$.
- 该函数也叫“soft max”, 因为它光滑的近似 $\max_{i=1, \dots, k} (a_i^T x + b_i)$

对于凸性的证明: 首先利用仿射组合规则, 即 $f(x) = \log(\sum_{i=1}^n e^{x_i})$
然后利用二阶特性证明 $f(x)$ 的凸性

$$\nabla_i f(x) = \frac{e^{x_i}}{\sum_{i=1}^n e^{x_i}}$$
$$\nabla_{ij}^2 f(x) = \frac{e^{x_i}}{\sum_{i=1}^n e^{x_i}} 1\{i = j\} - \frac{e^{x_i} e^{x_j}}{(\sum_{\ell=1}^n e^{x_\ell})^2}$$

$\nabla^2 f(x) = \text{diag}(z) - zz^T$, where $z_i = \frac{e^{x_i}}{\sum_{\ell=1}^n e^{x_\ell}}$. 该矩阵是对角占优矩阵, 因此是半正定的



为什么log-sum-exp函数是softmax函数？

➤通过泰勒展开式对 $f(x) = \log(\sum_{k=1}^p \exp x_i)$ 进行一阶近似

$$f(x) \approx f(x_0) + f'(x)(x - x_0).$$

对于 $f(x) = \log(x + a)$ 来说，令 $x_0 = x - a$ ，有

$$f(x) = \log(x + a) \approx f(x - a) + f'(x - a)(x - x_0) = \log x + \frac{1}{x}a$$

$$\text{因此} \log(x + a) \approx \log x + \frac{a}{x}$$

$$\text{相应地, } \log(\sum_{k=1}^p \exp(x_i)) \approx \log(\exp x_j) + \frac{\sum_{i \neq j} \exp x_i}{\exp x_j}$$

$$\text{不妨取} x_j = \max_i x_i, \text{ 则有} \log(\sum_{k=1}^p \exp(x_i)) > \max_i x_i \quad (1)$$

$$\text{由于} \sum_i x_i \leq n \times \max_i x_i, \text{ 且} \sum_i x_i \geq x_i$$

$$\max\{x_1, \dots, x_n\} = \log(\exp(\max_i x_i))$$

$$\leq \log(\exp x_1 + \dots + \exp x_n) = \log(\sum_{k=1}^p \exp(x_i))$$

$$\leq \log(n \times \exp(\max_i x_i))$$

$$\leq \max\{x_1, \dots, x_n\} + \log n \quad (2)$$

$$\max_i x_i < \log \left(\sum_{k=1}^p \exp(x_i) \right) \leq \max\{x_1, \dots, x_n\} + \log n$$



参考文献

- 运筹学与最优化方法, Page 32
- Convex Optimization, Stephen Boyd and Lieven Vandenberghe, Cambridge University Press, 2016. Chapters 4 and 3
- 网课: 最优化理论与方法
- 网课: Convex Optimization

