

运筹学与优化方法

晁国清

计算机科学与技术学院



课程回顾

➤ 线性规划的下界与对偶

Primal LP:

$$\begin{aligned} \min_{\mathbf{x}} \quad & c^T \mathbf{x} \\ \text{s.t.} \quad & A\mathbf{x} = \mathbf{b} \\ & G\mathbf{x} \leq \mathbf{h} \end{aligned}$$

Dual LP:

$$\begin{aligned} \max_{\mathbf{u}, \mathbf{v}} \quad & -\mathbf{b}^T \mathbf{u} - \mathbf{h}^T \mathbf{v} \\ \text{s.t.} \quad & -A^T \mathbf{u} - G^T \mathbf{v} = \mathbf{c} \\ & \mathbf{v} \geq \mathbf{0} \end{aligned}$$

➤ 再看LP对偶

➤ 另外一种理解方式：对于任意的 $\mathbf{u}, \mathbf{v} \geq \mathbf{0}$ 以及主问题可行点 \mathbf{x} ，有

$$c^T \mathbf{x} \geq c^T \mathbf{x} + \mathbf{u}^T (A\mathbf{x} - \mathbf{b}) + \mathbf{v}^T (G\mathbf{x} - \mathbf{h}) = L(\mathbf{x}, \mathbf{u}, \mathbf{v})$$

如果 C 表示主问题可行集， f^* 表示主问题最优值，那么对于任意的 $\mathbf{u}, \mathbf{v} \geq \mathbf{0}$ ，有

$$f^* \geq \min_{\mathbf{x} \in C} L(\mathbf{x}, \mathbf{u}, \mathbf{v}) \geq \min_{\mathbf{x}} L(\mathbf{x}, \mathbf{u}, \mathbf{v}) = g(\mathbf{u}, \mathbf{v})$$

即 $g(\mathbf{u}, \mathbf{v})$ 对于任意 $\mathbf{u}, \mathbf{v} \geq \mathbf{0}$ 是 f^* 的一个下界

$$\text{注意: } g(\mathbf{u}, \mathbf{v}) = \begin{cases} -\mathbf{b}^T \mathbf{u} - \mathbf{h}^T \mathbf{v}, & \text{if } \mathbf{c} = -A^T \mathbf{u} - G^T \mathbf{v} \\ -\infty & \text{otherwise} \end{cases}$$

可以通过在任意 $\mathbf{u}, \mathbf{v} \geq \mathbf{0}$ 上最大化 $g(\mathbf{u}, \mathbf{v})$ 得到最靠近的一个界，也就得到了对偶线性规划



课程回顾

➤ 拉格朗日对偶函数

➤ 令 C 作为主可行集, f^* 表示主最优值, 在所有的 x 上最小化 $L(x, u, v)$ 给出一个下界

$$f^* \geq \min_{x \in C} L(x, u, v) \geq \min_x L(x, u, v) = g(u, v)$$

我们称 $g(u, v)$ 为拉格朗日对偶函数, 它给出了对

➤ 拉格朗日对偶问题

$$\begin{aligned} & \min_x f(x) \\ \text{s.t. } & h_i(x) \leq 0, i = 1, \dots, m \\ & \ell_j(x) = 0, j = 1, \dots, r \end{aligned}$$

$$\begin{aligned} & \max_{u, v} g(u, v) \\ \text{s.t. } & u \geq 0 \end{aligned}$$

➤ 软对偶与强对偶

之前讲了弱对偶 $f^* \geq g^*$ 当 $f^* = g^*$ 成立的时候就称之为强对偶



课程内容

- KKT (Karush-Kuhn-Tucker) 条件
- 举例
- 约束形式与拉格朗日形式



KKT条件

➤ 给定一个一般约束优化问题:

$$\begin{aligned} \min_x \quad & f(x) \\ \text{s.t.} \quad & h_i(x) \leq 0, i = 1, \dots, m \\ & \ell_j(x) = 0, j = 1, \dots, r \end{aligned}$$

KKT (Karush-Kuhn-Tucker) 条件是:

$$0 \in \nabla_x (f(x) + \sum_{i=1}^m u_i h_i(x) + \sum_{j=1}^r v_j \ell_j(x)) \quad (\text{stationarity})$$

$$u_i \cdot h_i(x) = 0 \text{ for all } i \quad (\text{complementary slackness})$$

$$h_i(x) \leq 0, \ell_j(x) = 0 \text{ for all } i, j \quad (\text{primal feasibility})$$

$$u_i \geq 0 \text{ for all } i \quad (\text{dual feasibility})$$



KKT条件的必要性

➤ x^* 和 u^*, v^* 分别是0对偶间隙主问题和对偶问题的解（强对偶成立，比如满足Slater's condition），则

$$\begin{aligned} f(x^*) &= g(u^*, v^*) \\ &= \min_x f(x) + \sum_{i=1}^m u_i^* h_i(x) + \sum_{j=1}^r v_j^* \ell_j(x) \\ &\leq f(x^*) + \sum_{i=1}^m u_i^* h_i(x^*) + \sum_{j=1}^r v_j^* \ell_j(x^*) \\ &\leq f(x^*) \end{aligned}$$

也就是说，所有这些不等式事实上都是等式



必要性

➤ 从上面的内容总结两点:

1. 点 x^* 最小化 $L(x, u^*, v^*)$ 。则 $L(x, u^*, v^*)$ 的子微分在 $x = x^*$ 处一定包含0, 这就是stationary condition。
2. 我们必须有 $\sum_{i=1}^m u_i^* h_i(x^*) = 0$, 因为每一项 $u_i^* h_i(x^*) \leq 0 \forall i$, 就意味着 $u_i^* h_i(x^*) = 0 \forall i$. 这就是complementary slackness

必要性: 如果 x^* 和 u^*, v^* 都分别是原问题和对偶问题的解, 并且原最优值和对偶最优值0间隙, 那么 x^* 和 u^*, v^* 满足KKT条件。

注意: 上述陈述并没有假设预先就有的关于问题的凸性, 即对于函数 f, h_i, ℓ_j 要求是凸函数



充分性

➤ 如果存在满足KKT条件的 x^*, u^*, v^* , 那么有

$$\begin{aligned} g(u^*, v^*) &= f(x^*) + \sum_{i=1}^m u_i^* h_i(x^*) + \sum_{j=1}^r v_j^* \ell_j(x^*) \\ &= f(x^*) \end{aligned}$$

第一个等式成立因为stationarity, 通过 $\nabla_x L = 0$ 可以解出 x^* , 然后代入拉格朗日。第二个等式成立因为complementary slackness $u_i^* h_i(x^*) = 0$ 并且 $v_j^* \ell_j(x^*) = 0$

因此, 对偶间隙为零 (并且 x^* 和 u^*, v^* 分别为原问题和对偶问题的可行解) 那么 x^* 和 u^*, v^* 分别是原问题和对偶问题的最优解。

充分性: 如果 x^* 和 u^*, v^* 满足KKT条件, 那么 x^* 和 u^*, v^* 都分别是原问题和对偶问题的最优解



充分性必要性

➤ 总结: KKT条件等价于0对偶间隙:

➤ 通常是充分的

➤ 在强对偶条件下是必要的

➤ 充分性必要性:

对于一个满足强对偶性的问题(比如, 假定满足Slater's condition: 凸问题并且存在一个严格满足非仿射不等式约束的 x), 则

x^* 和 u^*, v^* 分别是原问题和对偶问题的解

$\Leftrightarrow x^*$ 和 u^*, v^* 满足KKT条件

KKT 条件最初叫KT (Kuhn-Tucker) 条件, 在1951年由两位作者首次发表, 但是后来人们发现这些条件出现在Karush在1939年未发表的硕士学位论文里

对于一般的优化问题, KKT条件可以通过次梯度研究最优性条件推导出来:

$$0 \in \nabla f(x^*) + \sum_{i=1}^m N\{h_i \leq 0\}(x^*) + \sum_{j=1}^r N\{\ell_j = 0\}(x^*)$$

$N_C(x)$ 是 C 在 x 处的normal cone.

Normal cone: given any set C and point $x \in C$, the normal cone is

$$N_C(x) = \{g : g^T x \geq g^T y, \text{ for all } y \in C\}$$

This is always a convex cone, regardless of C .



举例：带等式约束的二次规划

➤ 考虑 $Q \succ 0$ 的二次规划问题：

$$\begin{aligned} \min_x \quad & \frac{1}{2} x^T Q x + c^T x \\ \text{s.t.} \quad & Ax = 0 \end{aligned}$$

这是一个凸问题，没有不等式约束，根据KKT条件

$$x \text{ 是一个解} \Leftrightarrow \begin{bmatrix} Q & A^T \\ A & 0 \end{bmatrix} \begin{bmatrix} x \\ u \end{bmatrix} = \begin{bmatrix} -c \\ 0 \end{bmatrix} \text{ for some } u.$$

上面的等式系统整合了stationary和primal feasibility条件

(complementary slackness 和 dual feasibility在该问题中都是没有意义的)



举例：Water-filling (B & V page 245)

➤考虑如下问题：

$$\begin{aligned} \min_x & - \sum_{i=1}^n \log(\alpha_i + x_i) \\ \text{s.t. } & x \geq 0, 1^T x = 1 \end{aligned}$$

信息理论：把 $\log(\alpha_i + x_i)$ 考虑为第 i 个信道的通信率。

上述问题的KKT条件是：

$$\begin{aligned} & -\frac{1}{\alpha_i + x_i} - u_i + v = 0, i = 1, \dots, n \\ & u_i \cdot x_i = 0, i = 1, \dots, n, \\ & x \geq 0, 1^T x = 1 \\ & u \geq 0 \end{aligned}$$

消去 u ，得到

$$\frac{1}{\alpha_i + x_i} \leq v, i = 1, \dots, n \quad (*)$$

$$\begin{aligned} & x_i \left(v - \frac{1}{\alpha_i + x_i} \right) = 0, i = 1, \dots, n \quad (**) \\ & x \geq 0, 1^T x = 1 \end{aligned}$$



举例: Water-filling

$$\begin{cases} -\frac{1}{\alpha_i + x_i} - u_i + v = 0, i = 1, \dots, n \\ u_i \cdot x_i = 0, i = 1, \dots, n, \\ x \geq 0, 1^T x = 1 \\ u \geq 0 \end{cases}$$

1. 如果 $v^* < \frac{1}{\alpha_i}$, 条件(*)只有在 $x_i^* > 0$ 时成立, 再由条件(**)得到 $v^* = \frac{1}{\alpha_i + x_i^*}$. 求解 x_i^* , 就得到 $x_i^* = \frac{1}{v^*} - \alpha_i$ 条件是 $v^* < \frac{1}{\alpha_i}$

2. 如果 $v^* \geq \frac{1}{\alpha_i}$, 那么 $x_i^* > 0$ 是不可能的, 因为这意味着 $v^* \geq \frac{1}{\alpha_i} > \frac{1}{\alpha_i + x_i^*}$, 这和 complementarity slackness 条件相悖。所以, 当 $v^* \geq \frac{1}{\alpha_i}$ 时, 有 $x_i^* = 0$

综上得到

$$x_i^* = \begin{cases} \frac{1}{v^*} - \alpha_i, & v^* < \frac{1}{\alpha_i} \\ 0, & v^* \geq \frac{1}{\alpha_i} \end{cases} = \max \left\{ 0, \frac{1}{v^*} - \alpha_i \right\}, i = 1, \dots, n$$

将上式代入 $1^T x = 1$, 就得到

$$\sum_{i=1}^n \max \left\{ 0, \frac{1}{v} - \alpha_i \right\} = 1$$

左边是 $\frac{1}{v}$ 的分段线性函数, 断点在 α_i , 所以该等式有一容易确定的唯一解



举例：Water-filling (B & V page 245)

➤跟water-filling的关系




Figure 5.7 Illustration of water-filling algorithm. The height of each patch is given by α_i . The region is flooded to a level $1/\nu^*$ which uses a total quantity of water equal to one. The height of the water (shown shaded) above each patch is the optimal value of x_i^* .

https://blog.csdn.net/just_h

将 α_i 视为patch i 上方的高度，然后用水填充到 $\frac{1}{\nu}$ 高度，如上图示，由于总用水量为 $\sum_{i=1}^n \max\{0, \frac{1}{\nu^*} - \alpha_i\}$ ，通过增加水位，直到总用水量为1，那么patch i 以上的水深就是最优值，即 x_i^*

举例：支持向量机SVM

➤ 给定 $y \in \{-1, 1\}^n$ 和 $X \in R^{n \times p}$, 支持向量机问题可表示为:

$$\begin{aligned} \min_{\beta, \beta_0, \xi} \quad & \frac{1}{2} \|\beta\|_2^2 + C \sum_{i=1}^n \xi_i \\ \text{s.t.} \quad & \xi_i \geq 0, i = 1, \dots, n \\ & y_i(x_i^T \beta + \beta_0) \geq 1 - \xi_i, i = 1, \dots, n \end{aligned}$$

引入对偶变量 $v, w \geq 0$. KKT stationary condition:

$$0 = \sum_{i=1}^n w_i y_i, \quad \beta = \sum_{i=1}^n w_i y_i x_i, \quad w = C1 - v$$

Complementary slackness:


$$v_i \xi_i = 0, \quad w_i (1 - \xi_i - y_i(x_i^T \beta + \beta_0)) = 0, i = 1, \dots, n$$

因此, 在最优解处有 $\beta = \sum_{i=1}^n w_i y_i x_i$, 并且 w_i 是非零的仅当 $y_i(x_i^T \beta + \beta_0) = 1 - \xi_i$. 满足这些条件的点称为支撑点 (support points)



举例：支持向量机SVM

- 对于支撑点 i , 如果 $\xi_i = 0$, 那么 x_i 就落在间隔的边上, 并且 $w_i \in (0, C]$;
- 对于支撑点 i , 如果 $\xi_i \neq 0$, 那么 x_i 就落在间隔的错的一面, 并且 $w_i = C$



KKT条件事实上并没有给寻找最优解的途径, 但是给了一个比较好的理解

事实上, 我们在执行最优化之前, 可以用KKT条件去掉非支撑点

约束形式和拉格朗日形式

➤通常，在统计和机器学习领域，我们会在约束形式和拉格朗日形式之间进行切换。

➤约束形式：

$$\begin{aligned} \min_x \quad & f(x) \\ \text{s.t.} \quad & h(x) \leq t \end{aligned} \quad (C)$$

这里 $t \in R$ 就是一个要调的参数

➤拉格朗日形式：

$$\min_x f(x) + \lambda \cdot h(x) \quad (L)$$

这里 $\lambda \geq 0$ 是一个可调的参数

两种形式(C)和(L)是等价的，要求 $f(x)$ 和 $h(x)$ 是函数。

(C)到(L)：如果C严格可行，那么强对偶成立，如果再存在一个 $\lambda \geq 0$ ，那么(C)中的任意解可最小化

$$f(x^*) + \lambda \cdot (h(x^*) - t)$$

因此， x^* 也是形式(L)的一个解



约束形式和拉格朗日形式

- (L) 到 (C): 如果 x^* 是形式 (L) 中的一个解, 令 $t = h(x^*)$, 形式 (C) 的 KKT 条件就得到满足, 从而 x^* 就是形式 (C) 的一个解。
- 结论:

$$\bigcup_{\lambda \geq 0} \{(L) \text{ 的解} \} \subseteq \bigcup_{t \geq 0} \{(C) \text{ 的解} \}$$
$$\bigcup_{\lambda \geq 0} \{(L) \text{ 的解} \} \supseteq \bigcup_{\substack{\text{令 (C) 严格可行的 } t \\ t \geq 0}} \{(C) \text{ 的解} \}$$

注意: 可以产生一个可行但不严格可行约束集 t 的唯一值是 $t = 0$, 我们也可以得到完美的等价

比如: 如果 $h \geq 0$ 并且问题 (C) 与 (L) 对于 $t \geq 0, \lambda \geq 0$ 分别可行, 那么我们就可以得到完美的等价



关于对偶

➤对偶的重要应用：在强对偶条件下，可以通过求解对偶问题解达到求解原问题解的目的

在强对偶条件下，KKT条件对于最优性是必要的。给定对偶解 u^*, v^* ，任何原问题解 x^* 满足stationarity condition

$$0 \in \nabla f(x^*) + \sum_{i=1}^m u_i^* \nabla h_i(x^*) + \sum_{j=1}^r v_j^* \nabla \ell_j(x^*)$$

即： x^* 是 $\min_x L(x, u^*, v^*)$

特别是，如果该解 x^* 唯一满足即问题 $\min_x L(x, u^*, v^*)$ 有唯一最小解，那么相应的解就是原问题最优解。这在对偶问题比原问题容易求解的时候非常有用



参考文献

- 运筹学与最优性条件, 第6章, Page133-144
- Convex Optimization, CMU, theory II
Duality and optimality
- S. Boyd and L. Vandenberghe (2004),
“Convex optimization”, Chapter 5
- R. T. Rockafellar (1970), “Convex
analysis”, Chapters 28 - 30

