

# 运筹学与优化方法

晁国清

计算机科学与技术学院



# 课程回顾

---

- 只有等式约束的KT (Kuhn-Tucker)条件
- 只有不等式约束的KT条件
- 举例
- 一般约束的KT条件
- 凸规划的一阶充分条件



# 课程内容

---

➤ 对偶范数

➤ 对偶函数

➤ 对偶锥

➤ 对偶技巧



# 对偶范数

➤  $\|x\|$  是一个范数，例如

$\ell_p$  范数:  $\|x\|_p = (\sum_{i=1}^n |x_i|^p)^{\frac{1}{p}}$  for  $p \geq 1$

迹范数 (Trace norm):  $\|X\|_{tr} = \sum_{i=1}^r \sigma_i(X)$ ,  $\sigma(X)$  表示矩阵  $X$  的奇异值

对偶范数  $\|x\|_*$  定义为

$$\|x\|_* = \max_{\|z\| \leq 1} z^T x$$

含义: 对于一个范数小于等于1的向量  $z$ ,  $z$  与  $x$  的内积最大值就是  $x$  的对偶范数

得到不定式  $|z^T x| \leq \|z\| \|x\|_*$  (泛化的Holder不等式), 对于上面的两个例子, 有

$\ell_p$  对偶范数:  $(\|x\|_p)_* = \|x\|_q$ ,  $\frac{1}{p} + \frac{1}{q} = 1$

迹范数对偶范数:  $(\|X\|_{tr})_* = \|X\|_{op} = \sigma_1(X)$



# 对偶范数

➤ 对偶范数的对偶是其本身:  $\|x\|_{**} = \|x\|$

证明: 问题  $\min_y \|y\| \quad s.t. \quad y = x$  的最优值是  $\|x\|$

拉格朗日  $L(y, u) = \|y\| + u^T(x - y) = \|y\| - y^T u + x^T u$

利用对偶范数的定义,

$$\min_y \{\|y\| - y^T u\} = \begin{cases} 0, & \|u\|_* \leq 1 \\ -\infty, & \|u\|_* > 1 \end{cases}$$

因此, 拉格朗日对偶问题变为:

$$\max_u u^T x \quad s.t. \quad \|u\|_* \leq 1$$

这定义了对偶范数的范数, 利用强对偶  $f^* = g^*$ , 即  $\|x\|_{**} = \|x\|$

如果  $\|u\|_* > 1$ , 那么存在  $\|y\| \leq 1$  使得  $y^T u = \|u\|_* > 1$ , 从而  $\|y\| - y^T u \rightarrow -\infty$ , 当  $y^T u \rightarrow \infty$

如果  $\|u\|_* \leq 1$ , 那么存在  $\|y\| \leq 1$  使得  $y^T u = \|u\|_* \leq 1$ , 从而  $\|y\| - y^T u \geq \|y\| - \|y\| \|u\|_* \geq 0$ , 从而当  $y = 0$  时,  $\|y\| - y^T u = 0$




# 共轭函数

➤ 给定一个函数  $f: R^n \rightarrow R$ , 定义它的共轭函数  $f^*: R^n \rightarrow R$ ,

$$f^*(y) = \max_x y^T x - f(x)$$

注意  $f^*$  通常是凸函数, 为什么?

因为它是对于  $y$  的凸函数的逐点最大化



$f^*(y)$ : 线性函数  $y^T x$  和  $f(x)$  之间的最大间隙

对于可微的  $f$ , 共轭称作勒让德变换(Legendre transform)

# 共轭函数

➤ 性质:

➤ 芬切尔不等式(Fenchel's inequality): 对于任意的 $x, y$ ,

$$f(x) + f^*(y) \geq x^T y$$

➤ 共轭的共轭 $f^{**}$ 满足 $f^{**} \leq f$

➤ 如果 $f$ 是封闭(所有下水平集都是封闭)且凸的, 那么,  $f^{**} = f$

➤ 如果 $f$ 是封闭且凸的, 那么对于任意的 $x, y$ , 有

$$x \in \partial f^*(y) \Leftrightarrow y \in \partial f(x)$$

$$\Leftrightarrow f(x) + f^*(y) = x^T y$$

➤ 如果 $f(u, v) = f_1(u) + f_2(v)$ , 那么 $f^*(w, z) = f_1^*(w) + f_2^*(z)$

独立函数的和的共轭等于独立函数的共轭的和



# 共轭函数

➤ 举例:

➤ 简单的二次规划:  $f(x) = \frac{1}{2}x^T Qx$ ,  $Q \succ 0$ ,

$y^T x - \frac{1}{2}x^T Qx$  对于  $y$  是严格凹的, 并且在  $x^* = Q^{-1}y$  处取得最大值, 从而

$$f^*(y) = \frac{1}{2}y^T Q^{-1}y$$

➤ 指示函数: 如果  $f(x) = I_C(x)$ , 那么它的共轭是

$$f^*(y) = \max_{x \in C} y^T x - I_C(x) = \max_{x \in C} y^T x = I_C^*(y)$$

被称作  $C$  的支撑函数

➤ 范数: 如果  $f(x) = \|x\|$ , 那么它的共轭是

$$f^*(y) = I_{\{z: \|z\|_* \leq 1\}}(y)$$

这里  $\|\cdot\|_*$  是  $\|\cdot\|$  的对偶范数





# 举例: Lasso dual

➤ 给定  $y \in \mathbb{R}^n, X \in \mathbb{R}^{n \times p}$ , Lasso (Least absolute shrinkage and selection operator) 问题即:

$$\min_{\beta} \frac{1}{2} \|y - X\beta\|_2^2 + \lambda \|\beta\|_1$$

它的对偶函数是一个常数  $f^*$ 。我们把原问题进行变换, 得

$$\begin{aligned} \min_{\beta, z} \quad & \frac{1}{2} \|y - z\|_2^2 + \lambda \|\beta\|_1 \\ \text{s.t.} \quad & z = X\beta \end{aligned}$$



# 举例: Lasso dual

对偶函数是

$$\begin{aligned} g(u) &= \min_{\beta, z} \frac{1}{2} \|y - z\|_2^2 + \lambda \|\beta\|_1 + u^T (z - X\beta) \\ &= \min_z \left( \frac{1}{2} \|y - z\|_2^2 + u^T z \right) \\ &\quad + \min_{\beta} (\lambda \|\beta\|_1 - (X^T u)^T \beta) \\ &= \frac{1}{2} \|y\|_2^2 - \frac{1}{2} \|y - u\|_2^2 \\ &\quad + \min_{\beta} \lambda \left( \|\beta\|_1 - \frac{(X^T u)^T \beta}{\lambda} \right) \\ &= \frac{1}{2} \|y\|_2^2 - \frac{1}{2} \|y - u\|_2^2 - \lambda I_{\{v: \|v\|_{\infty} \leq 1\}} \left( \frac{X^T u}{\lambda} \right) \end{aligned}$$



# 举例: Lasso dual

因此, Lasso对偶问题是 $\max_u \frac{1}{2} (\|y\|_2^2 - \|y - u\|_2^2) \text{ s.t. } \|X^T u\|_\infty \leq \lambda \Leftrightarrow \min_u \|y - u\|_2^2 \text{ s.t. } \|X^T u\|_\infty \leq \lambda$

对偶问题是通过作变换 $z = X\beta$ 推导出来的, 故两者等价。  
Slater 条件成立, 则强对偶也成立。

注意: 最优一个问题的最优值不一定是原问题的最优值  
对于 $z$ 的KKT稳定性条件给出了对偶解, 任何对偶解都满足  
 $X\beta = y - u$



# 举例: Lasso dual




Figure 13.2: Visualization of Lasso Dual Problem, where its solution looks like projection of  $y$  onto set  $C$ , a polyhedron mapped from a hypercube.

对偶问题的解看起来像把 $y$ 投影到集合 $C = \{u: \|X^T u\|_\infty \leq \lambda\} = (X^T)^{-1}\{v: \|v\|_\infty \leq \lambda\}$ . 这个概念呈现如上图。集合 $C$ 是一个从立方体映射过来的多面体。这是线性映射下的逆像(inverse image)。多面体的每一面对应Lasso选择的active set。当把 $y$ 投影到一个面的时候, 所有的 $y_i$ 共享Lasso解的符号的active set。这些符号的active sets 是局部常数, 我们可把lasso看做像变量选择器一样稳定。

# 共轭和对偶问题的关系

➤ 共轭常常出现在对偶问题的推导中，如通过

$$-f^*(u) = \min_x f(x) - u^T x$$

最小化拉格朗日  
例如

$$\min_x f(x) + g(x)$$

等价于

$$\begin{aligned} \min_{x,z} \quad & f(x) + g(z) \\ \text{s.t.} \quad & x = z \end{aligned}$$

对偶函数是：

$$\begin{aligned} g(u) &= \min_x f(x) + g(z) + u^T(z - x) \\ &= -f^*(u) - g^*(-u) \end{aligned}$$

相应的，对偶问题：

$$\max_u -f^*(u) - g^*(-u)$$



# 共轭和对偶问题的关系

➤ 举例:

➤ 指示函数 (Indicator function):

$$\text{Primal: } \min_x f(x) + I_C(x)$$

$$\text{Dual: } \max_u -f^*(u) - I_C^*(-u)$$

这里的  $I_C^*$  是  $C$  的支撑函数

➤ 范数 (Norms):

$$\text{Primal: } \min_x f(x) + \|x\|$$

$$\begin{aligned} \text{Dual: } & \max_u -f^*(u) \\ \text{s.t. } & \| -u \|_* \leq 1 \end{aligned}$$



# 线性变化的切换 (Shifting linear transformations)

➤ 对偶公式可以帮助我们 把一个目标函数的一部分变为对偶函数的一部分。问题

$$\min_x f(x) + g(Ax)$$

等价于

$$\begin{aligned} \min_{x,z} \quad & f(x) + g(z) \\ \text{s.t.} \quad & Ax = z \end{aligned}$$

与之前一样，其对偶为 ( $L = f(x) + g(z) + u^T(z - Ax)$ )

$$\max_u -f^*(A^T u) - g^*(-u)$$

举例：对于一个范数和它的对偶范数,  $\|\cdot\|$  与  $\|\cdot\|_*$  :

$$\text{Primal: } \min_x f(x) + \|Ax\|$$

$$\begin{aligned} \text{Dual: } \quad & \max_u -f^*(A^T u) \\ \text{s.t.} \quad & \| -u \|_* \leq 1 \end{aligned}$$

$$\begin{aligned} & \min_{x,z} f(x) + \|z\| + u^T(z - Ax) \\ & = \min_x f(x) - (A^T u)^T x + \min_z \|z\| + u^T z \\ & = -f^*(A^T u) - I_{\{v: \|v\|_* \leq 1\}}(-u) \end{aligned}$$




# 对偶锥

➤ 对于一个锥  $K \subseteq \mathbb{R}^n$  ( $x \in K, t \geq 0 \Rightarrow tx \in K$ ), 其对偶锥定义为:

$$K^* = \{y: y^T x \geq 0 \text{ for all } x \in K\}$$

这通常是一个凸锥 (即便  $K$  不是凸的)



注意:  $y \in K^* \Leftrightarrow$  半空间  $\{x: y^T x \geq 0\}$  包含  $K$

重要性质: 如果  $K$  是一个封闭的凸锥, 那么  $K^{**} = K$



# 对偶锥

➤ 举例:

➤ 线性空间 (Linear subspace): 一个线性空间  $V$  的对偶锥是  $V^\perp$ , 它的正交补, 如  $(\text{row}(A))^* = \text{null}(A)$

➤ 范数锥 (Norm Cone): 范数锥

$$K = \{(x, t) \in \mathbb{R}^{n+1} : \|x\| \leq t\}$$

的对偶锥是它的对偶范数的范数锥,

$$K^* = \{(y, s) \in \mathbb{R}^{n+1} : \|y\|_* \leq s\}$$

正半定锥 (Positive Semidefinite cone): 凸锥  $\mathbb{S}_+^n$  是自对偶的 (self-dual), 意味着  $(\mathbb{S}_+^n)^* = \mathbb{S}_+^n$ . 为什么?

$$Y \succeq 0 \Leftrightarrow \text{tr}(YX) \geq 0 \text{ for all } X \succeq 0$$

通过检查  $X$  的特征值分解

$\text{row}(A) = \text{the set of } A^T x$ ;  $\text{null}(A) = \text{the set of } y \text{ such that } Ay = 0$ ;

$$\langle y, A^T x \rangle = y^T (A^T x) = x^T (Ay) = x^T 0 = 0$$



# 对偶锥和对偶问题

➤ 考虑锥约束问题:

$$\begin{aligned} \min_x & f(x) \\ \text{s.t.} & Ax \in K \end{aligned}$$

它的对偶问题是:

$$\max_u -f^*(A^T u) - I_K^*(-u)$$

这里  $I_K^*(y) = \max_{z \in K} z^T y$ ,  $K$  的支撑函数。如果  $K$  是一个锥, 那么这就是

$$\begin{aligned} \max_u & -f^*(A^T u) \\ \text{s.t.} & u \in K^* \end{aligned}$$

这里  $K^*$  是  $K$  的对偶锥, 因为  $I_K^*(-u) = I_{K^*}(u)$

这是一个有用的观察, 因为很多不同形式的约束可以视作锥约束



# 对偶技巧

➤通常，我们会把对偶转化为等价的问题并称之为对偶问题。在强对偶条件下，我们可以用对偶问题的解计算原问题的解。

警告：转换的对偶问题的最优值未必是原问题的最优值

➤推导无约束问题对偶的一个常见技巧是增加一个哑变量 (dummy variable) 和等式约束来转换原问题

不同的选择会产生不同的对偶问题



# 双对偶(Double dual)

➤ 考虑带线性约束的一般最小化问题：

$$\begin{aligned} \min_{\mathbf{x}} \quad & f(\mathbf{x}) \\ \text{s.t.} \quad & A\mathbf{x} \leq \mathbf{b} \\ & C\mathbf{x} = \mathbf{d} \end{aligned}$$

其拉格朗日是

$$L(\mathbf{x}, \mathbf{u}, \mathbf{v}) = f(\mathbf{x}) + (A^T \mathbf{u} + C^T \mathbf{v})^T \mathbf{x} - b^T \mathbf{u} - d^T \mathbf{v}$$

因此，其对偶问题为：

$$\begin{aligned} \max_{\mathbf{u}, \mathbf{v}} \quad & -f^*(-A^T \mathbf{u} - C^T \mathbf{v}) - b^T \mathbf{u} - d^T \mathbf{v} \\ \text{s.t.} \quad & \mathbf{u} \geq 0 \end{aligned}$$

回顾共轭的性质：当 $f$ 是封闭且凸时， $f^{**} = f$ 。  
在这里，对偶的对偶就是原问题



# 双对偶(Double dual)

➤事实上，对偶的对偶与共轭之间的关联不局限于线性约束。

考虑如下问题：

$$\begin{aligned} \min_x \quad & f(x) \\ \text{s.t.} \quad & h_i(x) \leq 0, \quad i = 1, \dots, m \\ & \ell_j(x) = 0, j = 1, \dots, r \end{aligned}$$

如果 $f$ 和 $h_1, \dots, h_m$ 都是封闭和凸的， $\ell_1, \dots, \ell_r$ 是仿射的，那么对偶的对偶就是原问题

这可以通过双函数(bifunction)的最小化问题进行证明。在此框架下，对偶函数对应于双函数的共轭(更多内容，可以参考Rockafellar 书的29和30章)。



# 参考文献

---

- Convex Optimization, CMU, theory II  
Duality and optimality
- S. Boyd and L. Vandenberghe (2004),  
“Convex optimization”, Chapter 2, 3, 5
- R. T. Rockafellar (1970), “Convex  
analysis”, Chapters 14, 16, 28 – 30

